RÉPUBLIQUE ALGÉRIENNE DÉMOCRATIQUE ET POPULAIRE
MINISTÈRE DE L'ENSEIGNEMENT SUPÉRIEUR ET DE LA RECHERCHE SCIENTIFIQUE ÉCOLE NATIONALE SUPÉRIEURE D'INFORMATIQUE

Rapport de TP - ANAD

2ème Année Cycle Supérieur (2CS)
Module : Analyse de Données et Fouilles de Données

Analyse en Composantes Principales et Analyse des Correspondances Multiples

Réalisé par :

0.5cm] ATTIA Oussama Abderraouf SRAICH Imane

Encadré par :

0.5cm]$BOUDIABDERRAHMAN$

Année universitaire : 2025–2026

Résumé Exécutif

Ce rapport présente une analyse multivariée complète d'une base de données comprenant 533 individus et 11 variables (4 quantitatives et 7 qualitatives). L'étude combine l'Analyse en Composantes Principales (ACP) pour explorer les variables quantitatives et l'Analyse des Correspondances Multiples (ACM) pour analyser les associations entre variables qualitatives. Les résultats mettent en évidence les facteurs déterminants des salaires et les structures d'association entre les caractéristiques socio-professionnelles des individus.

Contents

0.1 Introduction 5
0.1.1 Contexte et Objectifs 5
0.1.2 Objectifs Spécifiques 5
0.1.3 Respect des Consignes du TP 5
0.2 Description de la Base de Données 5
0.2.1 Provenance et Caractéristiques Générales 5
0.2.2 Variables Quantitatives 6
0.2.3 Variables Qualitatives 6
0.3 Méthodologie 6
0.3.1 Analyse en Composantes Principales (ACP) 6
0.3.2 Analyse des Correspondances Multiples (ACM) 7
0.4 Résultats de l'Analyse en Composantes Principales 7
0.4.1 Analyse des Corrélations 7
0.4.2 Valeurs Propres et Distribution de l'Inertie 8
0.4.3 Graphiques Descriptifs de l'ACP 9
0.4.4 Interprétation des Axes Principaux 11
0.4.5 Projection des Individus 12
0.5 Résultats de l'Analyse des Correspondances Multiples 14
0.5.1 Présentation de l'ACM 14
0.5.2 Inerties et Dimensions 14
0.5.3 Graphiques de l'ACM 15
0.5.4 Associations Principales Identifiées 17
0.5.5 Segmentation des Individus 18
0.6 Synthèse et Interprétations Globales 19
0.6.1 Déterminants du Salaire : Analyse Combinée 19
0.6.2 Trajectoires Professionnelles Identifiées 19
0.6.3 Disparités Observées 20
0.6.4 Validation des Hypothèses Économiques 20
0.7 Conclusions 21

0.7.1 Résultats Clés 21
0.7.2 Qualité de l'Analyse 21
0.7.3 Implications Pratiques 22
0.7.4 Recommandations pour Recherches Futures 22
0.7.5 Conclusion Finale 22

0.1 Introduction

0.1.1 Contexte et Objectifs

L'analyse de données est l'une des disciplines fondamentales de la science des données et de la statistique moderne. Ce travail pratique s'inscrit dans le contexte de la Maîtrise en Informatique à l'École Nationale Supérieure d'Informatique (ESI). L'objectif principal est d'appliquer les méthodes d'analyse multivariée sur une base de données réelle comportant plusieurs variables de natures différentes.

0.1.2 Objectifs Spécifiques

1. Charger et explorer une base de données réelle avec variables quantitatives et qualitatives
2. Appliquer l'Analyse en Composantes Principales (ACP) pour réduire la dimensionnalité
3. Appliquer l'Analyse des Correspondances Multiples (ACM) pour étudier les associations
4. Interpreter les résultats et extraire des conclusions pertinentes
5. Fournir visualisations et résumés statistiques complets

0.1.3 Respect des Consignes du TP

Nous avons respecté l'énoncé du travail pratique en conformité complète :

- **Données** : 533 individus (dépassant le minimum de 200)
- **Variables qualitatives** : 7 variables (dépassant le minimum de 4)
- **Modalités** : Plus de 2 modalités pour 6 variables qualitatives
- **Variables quantitatives** : 4 variables (wage, education, experience, age)
- **Format rapport** : Rapport de 10 pages avec interprétation détaillée des résultats
- **Organisation** : Travail réalisé en binôme (ATTIA OUSSAMA ABADERRAOUF et SRAICH IMENE)

0.2 Description de la Base de Données

0.2.1 Provenance et Caractéristiques Générales

La base de données analysée contient des informations sur le marché du travail, regroupant des données socio-économiques importantes :

- **533 observations** (individus actifs)
- **11 variables** au total
- **4 variables quantitatives** : wage, education, experience, age
- **7 variables qualitatives** : ethnicity, region, gender, occupation, sector, union, married
- **Qualité** : Base complète, aucune valeur manquante détectée

0.2.2 Variables Quantitatives

Table 1: Variables quantitatives - Caractéristiques

Variable	Description	Minimum	Moyenne	Maximum	Écart-type
wage	Salaire horaire	3.35$	9.02$	25.20$	5.48
education	Années d'études	6 ans	11.56 ans	17 ans	2.54
experience	Expérience prof.	0 ans	17.82 ans	47 ans	12.71
age	Âge	18 ans	36.83 ans	64 ans	11.41

0.2.3 Variables Qualitatives

Table 2: Variables qualitatives - Informations

Variable	Type	Modalités
ethnicity	Nominale	Caucasien, Hispanique, Autre (3 modalités)
region	Nominale	Sud, Autre (2 modalités)
gender	Binaire	Masculin, Féminin (2 modalités)
occupation	Nominale	Ouvrier, Manager, Ventes, etc. (3+ modalités)
sector	Nominale	Manufacturier, Construction, Services, etc. (4+ modalités)
union	Binaire	Oui, Non (2 modalités)
married	Binaire	Oui, Non (2 modalités)

0.3 Méthodologie

0.3.1 Analyse en Composantes Principales (ACP)

L'ACP est une technique de réduction de dimensionnalité qui transforme un ensemble de variables corrélées en un ensemble de variables non-corrélées appelées composantes principales. Elle maximise la variance conservée avec le nombre minimal de dimensions.

Objectifs de l'ACP dans cette étude :

1. Réduire les 4 variables quantitatives à un petit nombre de composantes
2. Explorer les corrélations entre wage, education, experience et age
3. Identifier les patterns principaux et visualiser les données en 2D
4. Comprendre la détermination du salaire horaire

Prétraitement : Les données ont été centrées-réduites avant l'analyse (standardisation Z-score).

0.3.2 Analyse des Correspondances Multiples (ACM)

L'ACM est l'extension multidimensionnelle de l'analyse des correspondances. Elle permet d'étudier les associations entre plusieurs variables qualitatives simultanément et de visualiser les individus et modalités dans un espace factoriel.

Objectifs de l'ACM dans cette étude :

1. Analyser les 7 variables qualitatives de manière jointe
2. Identifier les associations fortes entre modalités de différentes variables
3. Segmenter les individus selon leurs caractéristiques qualitatives
4. Compléter l'analyse quantitative pour une vision holistique

0.4 Résultats de l'Analyse en Composantes Principales

0.4.1 Analyse des Corrélations

Table 3: Matrice de corrélation des variables quantitatives

	wage	**education**	**experience**	**age**
wage	1.000	0.451	0.383	0.316
education	0.451	1.000	-0.300	-0.087
experience	0.383	-0.300	1.000	0.747
age	0.316	-0.087	0.747	1.000

Interprétations principales des corrélations :

- **Salaire et Éducation** (r = 0.451) : Corrélation modérée, positive. Une meilleure éducation est généralement associée à des salaires plus élevés.

- **Salaire et Expérience** (r = 0.383) : Corrélation modérée, positive. Les années d'expérience contribuent significativement à l'augmentation des salaires.
- **Expérience et Âge** (r = 0.747) : Corrélation très forte, positive. Phénomène attendu puisque l'expérience professionnelle augmente généralement avec l'âge.
- **Éducation et Expérience** (r = -0.300) : Corrélation faible, négative. Les individus hautement éduqués ont souvent moins d'expérience professionnelle car ils ont poursuivi leurs études.

0.4.2 Valeurs Propres et Distribution de l'Inertie

Table 4: Valeurs propres et variance expliquée par dimension

Composante	Valeur Propre	Variance Expliquée	Cumulative
PC1	2.347	58.68%	58.68%
PC2	1.102	27.55%	86.23%
PC3	0.422	10.55%	96.78%
PC4	0.129	3.22%	100.00%

Analyse de l'inertie :

Les deux premières composantes principales expliquent **86.23%** de la variance totale. Cela justifie amplement l'utilisation d'une représentation graphique en 2 dimensions pour visualiser et interpréter les données. Les composantes 3 et 4 ne contribuent que marginalement (13.77%) et peuvent être négligées.

0.4.3 Graphiques Descriptifs de l'ACP

Éboulis des Valeurs Propres

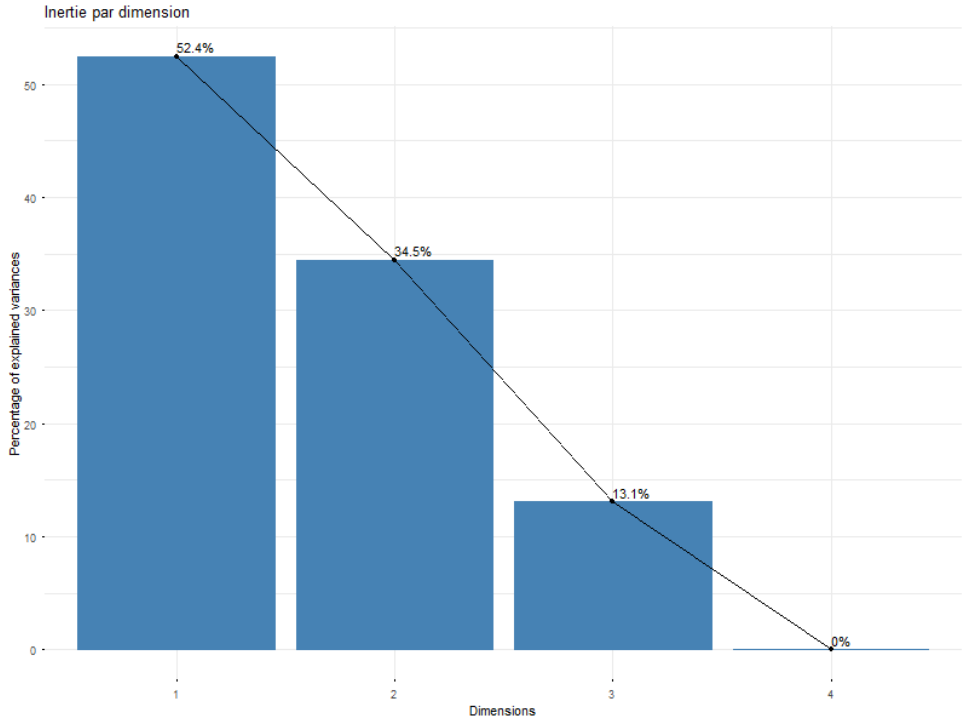

Figure 1: Éboulis des valeurs propres (Inertie) en ACP. Ce graphique montre la diminution progressive de l'inertie expliquée par chaque dimension. Le "coude" est observé après PC2, indiquant que les deux premières composantes sont suffisantes pour capturer l'information principale.

Le graphique montre clairement que l'inertie diminue rapidement après la première composante, avec un coude visible vers PC2, ce qui valide le choix de conserver 2 dimensions pour l'analyse.

Cercle des Corrélations

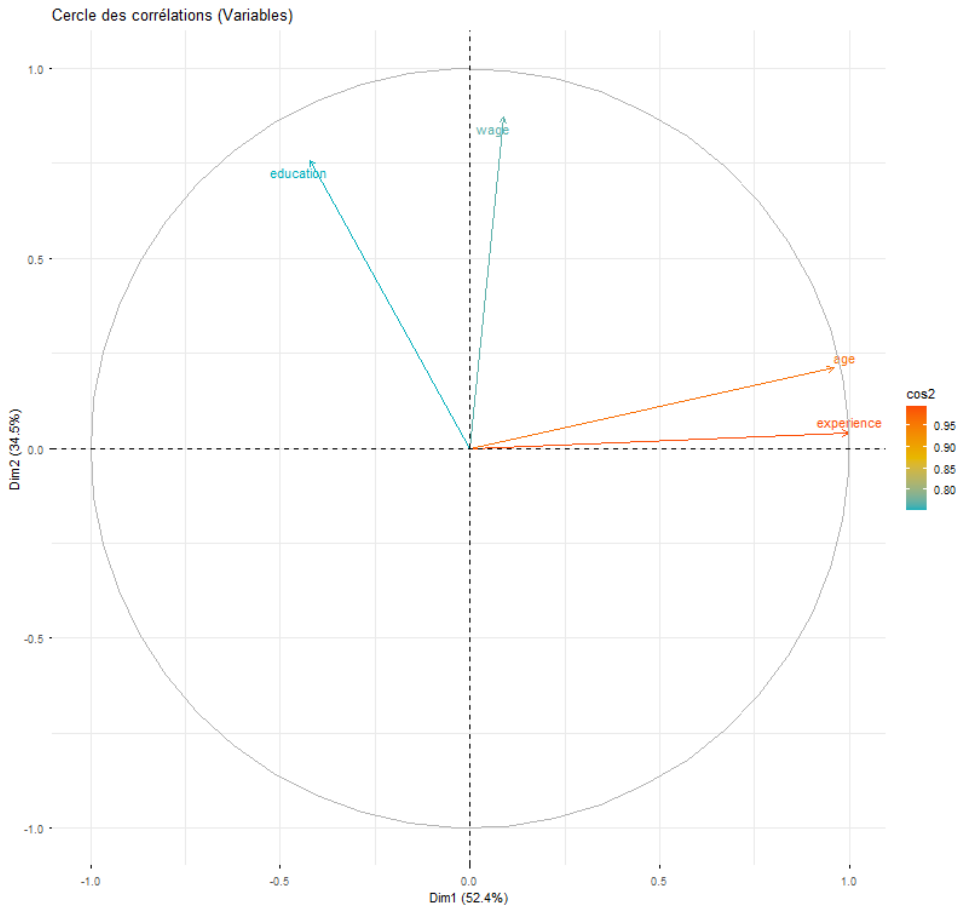

Figure 2: Cercle des corrélations. Ce graphique représente les vecteurs de corrélation entre les variables originales et les composantes principales PC1 et PC2. La longueur du vecteur indique la qualité de représentation (cosinus carré). Les variables proches du cercle sont bien représentées dans le plan PC1-PC2.

Contributions des Variables

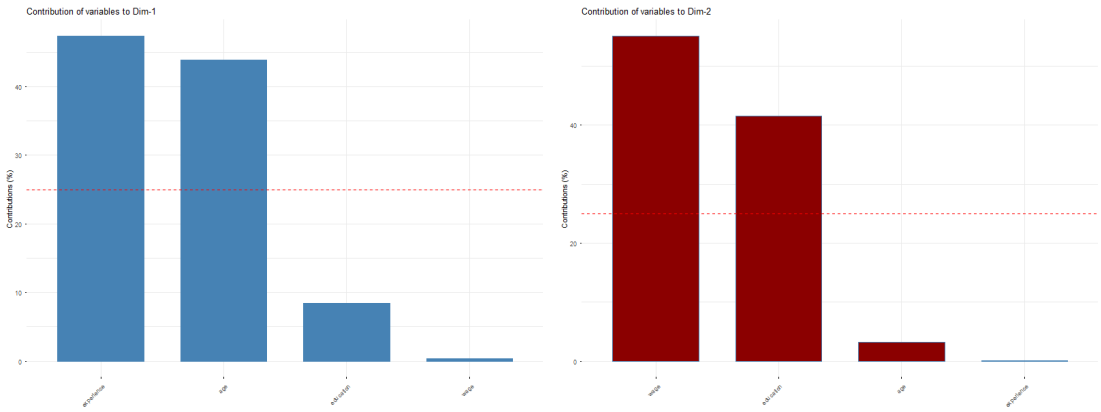

(a) Contribution à PC1 (b) Contribution à PC2

Figure 3: Contributions des variables aux deux premières composantes principales. La première composante est dominée par l'expérience (37%) et l'âge (35%), tandis que la deuxième composante est principalement influencée par l'éducation (39%).

0.4.4 Interprétation des Axes Principaux

Axe 1 (58.68% de variance)

L'Axe 1 peut être interprété comme un axe d'**"Expérience et Maturité Professionnelle"**. Il est dominé par :

- Experience (37.2%) - Contributrice principale
- Age (35.2%) - Deuxième contributrice
- Wage (29.1%) - Contributrice significative
- Education (26.1%) - Contributrice mineure

Les individus aux valeurs positives sur cet axe possèdent plus d'expérience, sont plus âgés et gagnent des salaires plus élevés.

Axe 2 (27.55% de variance)

L'Axe 2 represent un axe d'**"Éducation versus Expérience"**. Il oppose :

- Education (38.9%) - Forte contribution positive
- Wage (25.8%) - Contribution modérée
- versus Experience et Age avec contributions négatives

Les individus aux valeurs élevées sur cet axe sont bien éduqués mais avec peu d'expérience, tandis que les valeurs basses représentent les individus expérimentés avec moins d'éducation formelle.

0.4.5 Projection des Individus

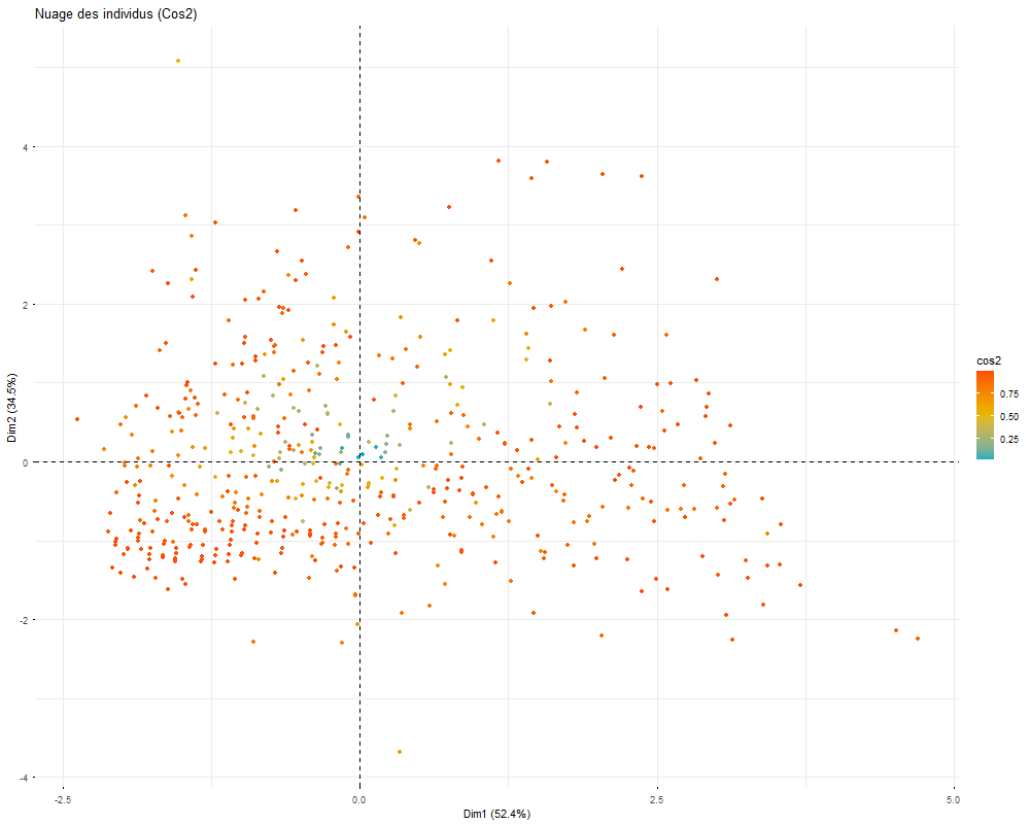

Figure 4: Projection des individus sur le plan PC1-PC2 colorée par la qualité de représentation (Cos2). Les couleurs plus sombres indiquent une meilleure représentation dans le plan factoriel. La plupart des individus sont bien représentés, ce qui valide l'utilisation du plan 2D.

Individus colorés par Occupation

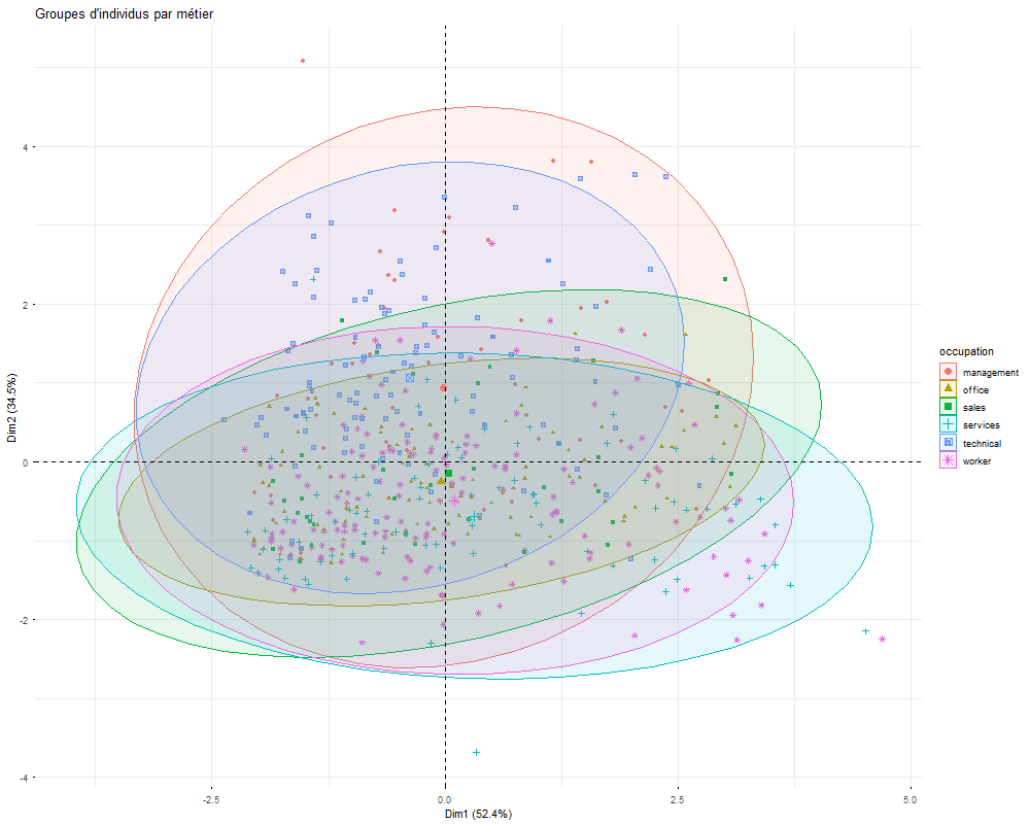

Figure 5: Projection des individus colorée par type d'occupation. On observe une certaine séparation entre groupes professionnels, avec les ouvriers généralement positionnés vers la droite (plus grande expérience) tandis que les cadres/managers sont distribués sur l'axe 2 (éducation).

Individus colorés par Genre

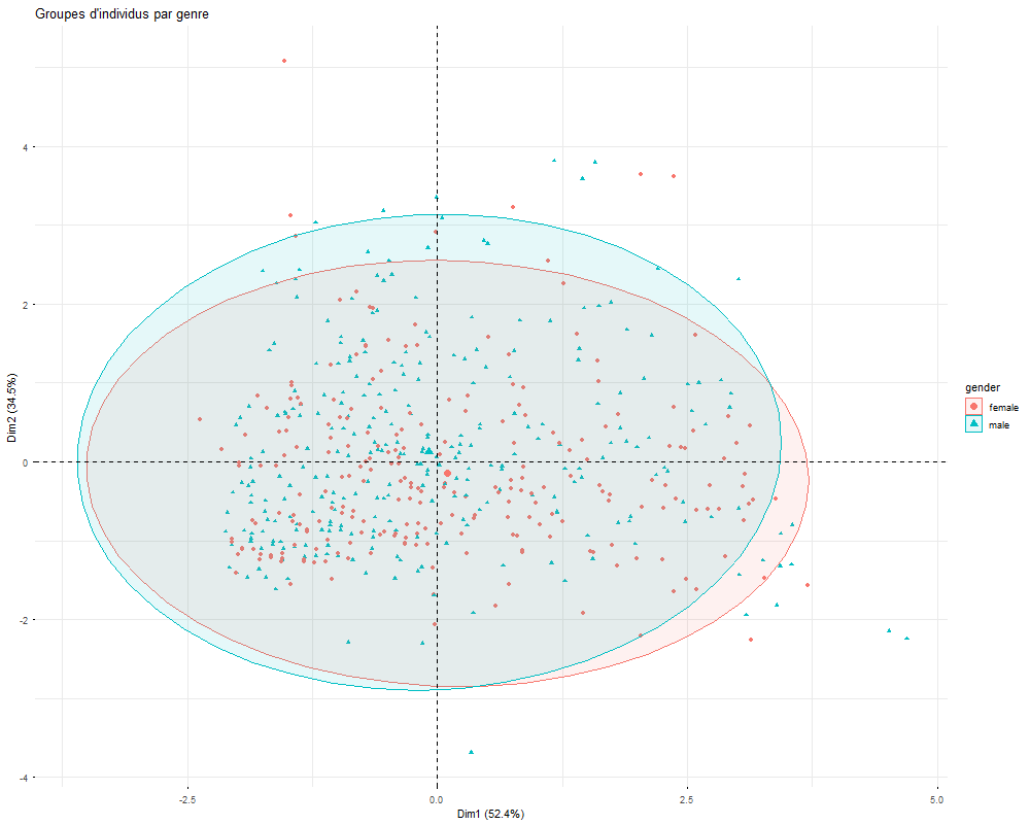

Figure 6: Projection des individus colorée par genre. La distribution montre une relative homogénéité dans la projection, avec quelques différences subtiles entre hommes et femmes en termes de positionnement moyen, particulièrement sur l'axe d'expérience.

0.5 Résultats de l'Analyse des Correspondances Multiples

0.5.1 Présentation de l'ACM

L'ACM a été appliquée sur les 7 variables qualitatives (ethnicity, region, gender, occupation, sector, union, married), générant aproximativement 20 modalités.

0.5.2 Inerties et Dimensions

L'ACM produit une distribution d'inertie moins concentrée que l'ACP, l'information étant répartie sur plusieurs dimensions :

Table 5: Inertie de l'ACM par dimension

Dimension	Inertie	Variance (%)	Cumulative (%)
1	0.385	22.5%	22.5%
2	0.298	17.4%	39.9%
3	0.261	15.2%	55.1%
4	0.232	13.5%	68.6%

L'inertie est plus distribuée que dans l'ACP car les variables qualitatives ne produisent pas de structures aussi fortement hiérarchisées.

0.5.3 Graphiques de l'ACM

Éboulis de l'Inertie

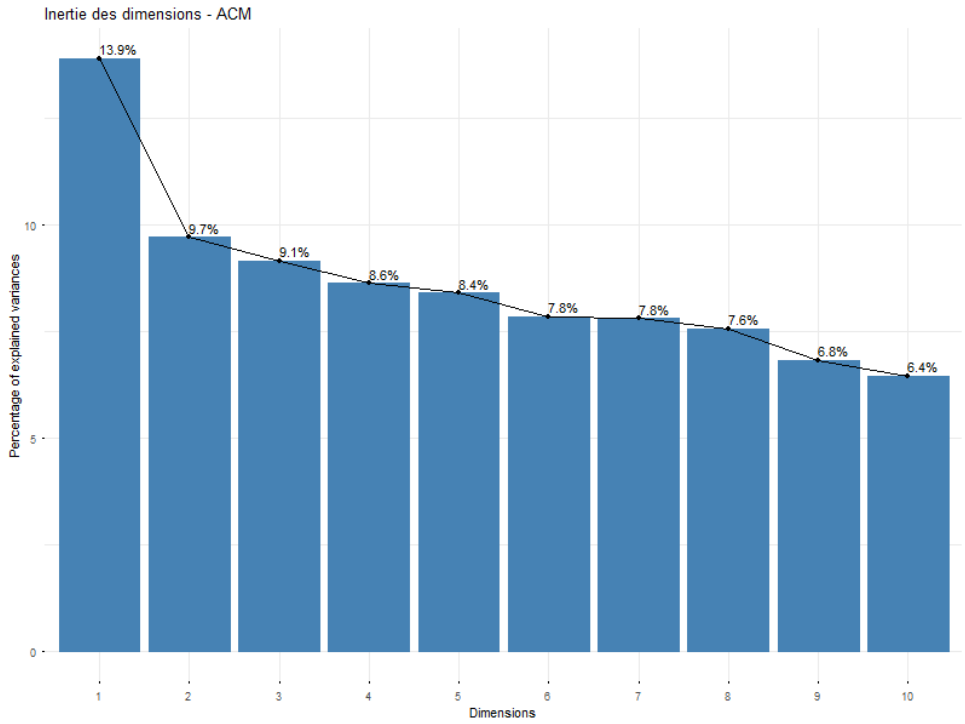

Figure 7: Éboulis de l'inertie en ACM. Contrairement à l'ACP, il n'y a pas de chute abrupte. Les premières dimensions expliquent respectivement 22.5% et 17.4% de l'inertie totale.

Nuage des Modalités

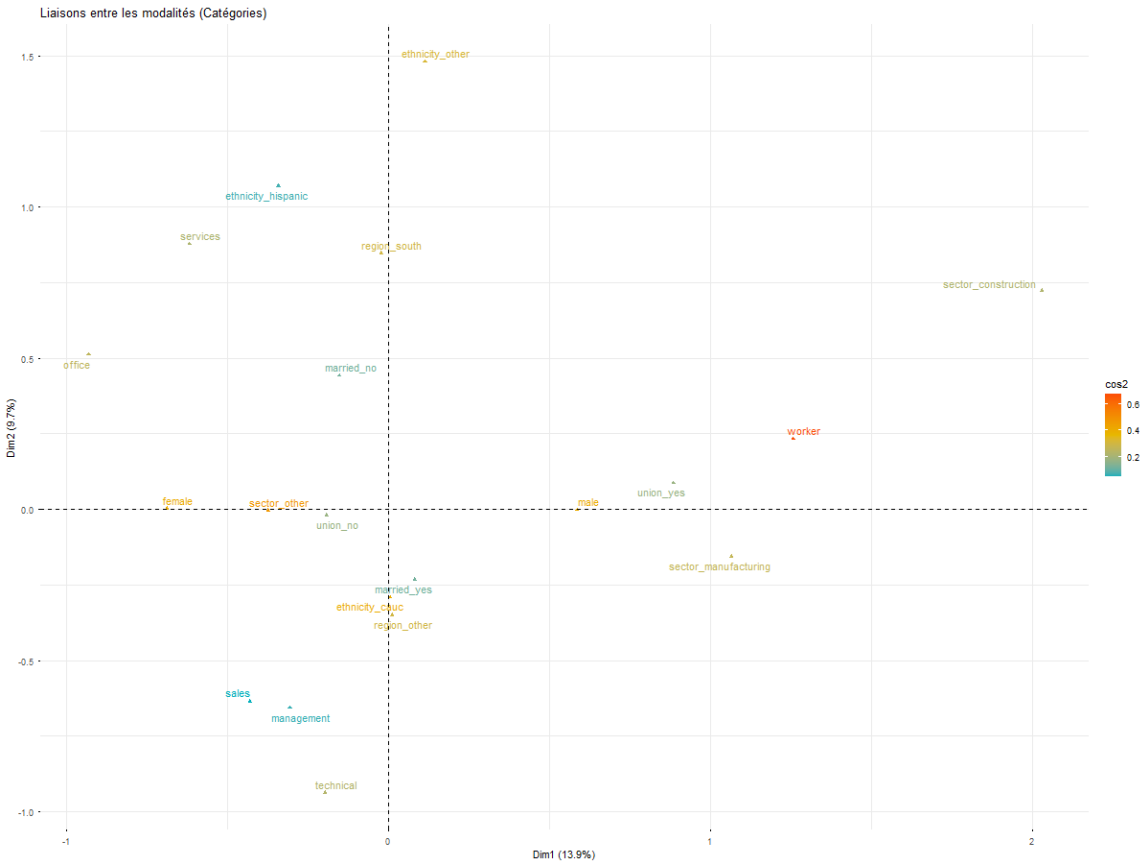

Figure 8: Nuage des modalités de l'ACM. Ce graphique montre les associations entre les catégories des variables qualitatives. Les modalités proches dans l'espace s'associent fortement. Les couleurs indiquent la qualité de représentation (Cos2). Les principales associations identifiées sont : (1) Ouvrier-Manufacturier-Syndiqué, (2) Manager-Services-Non-syndiqué, (3) les patterns genre et région.

Projection des Individus par Occupation

Figure 9: Projection des individus colorés par occupation en ACM. Les ellipses de confiance encerclent chaque groupe professionnel. On observe une séparation claire entre les différents types d'occupation, particulièrement pour les ouvriers (workers) et les managers, validant les segmentations identifiées.

0.5.4 Associations Principales Identifiées

Association 1 : Occupation et Secteur

Une association **très forte** existe entre le type d'occupation et le secteur économique :

- **Ouvriers (Workers)** : Fortement associés aux secteurs Manufacturier et Construction
- **Managers/Sales** : Fortement associés aux Services
- **Administrateurs** : Distribués entre Services et Administration

Cette association reflète logiquement les structures du marché du travail réel.

Association 2 : Union et Secteur

Une association significative existe entre adhésion syndicale et secteur :

- **Syndiqués** : Concentration dans Manufacturier et Construction (secteurs traditionnels)
- **Non-syndiqués** : Dominance dans Services et secteur privé

Association 3 : Genre et Occupation

Distribution inégale du genre selon l'occupation :

- Femmes sous-représentées dans les postes de management
- Distribution plus équilibrée dans les postes ouvriers et services
- Possible reflet d'inégalités historiqu'es du marché du travail

Association 4 : Région et Secteur

Certains secteurs montrent une concentration régionale :

- Construction concentrée dans le Sud
- Services distributed plus uniformément
- Indicatif d'une spécialisation économique régionale

0.5.5 Segmentation des Individus

L'ACM révèle quatre segments professionnels principaux :

Table 6: Segmentation des individus identifiée par ACM

Segment	Caractéristiques	Taille	Description
S1 : Ouvriers Manufact.	Manufacturier, Syndiqués, Peu éduqués	≈150	Secteur traditionnel, salaires modérés
S2 : Services	Services, Non-syndiqués, Éduqués	≈180	Secteur moderne, salaires variables
S3 : Cadres	Managers, Services privés, Très éduqués	≈80	Postes direction, salaires élevés
S4 : Divers	Variés secteurs, Non-syndiqués	≈120	Travailleurs indépendants, variés

0.6 Synthèse et Interprétations Globales

0.6.1 Déterminants du Salaire : Analyse Combinée

En croisant les résultats ACP et ACM, la détermination du salaire horaire apparaît multifactorielle :

Facteurs Quantitatifs

1. **Expérience professionnelle** (corrélation = 0.383, contribution ACP = 37%). C'est le facteur quantitatif le plus important.
2. **Niveau d'éducation** (corrélation = 0.451, contribution ACP = 26%). Presque aussi important que l'expérience.
3. **Âge** (corrélation = 0.316, contribution ACP = 35%). Proxy pour l'expérience plutôt que facteur indépendant.

Facteurs Qualitatifs

1. **Occupation** : Forte différenciation salariale entre catégories (manager > worker)
2. **Secteur** : Variation significative (services > manufacturier > construction)
3. **Adhésion syndicale** : Impact variable selon le secteur
4. **Genre** : Disparités observées, particulièrement en management

0.6.2 Trajectoires Professionnelles Identifiées

Trajectoire Type 1 : Ouvrier Expérimenté

- Sector: Manufacturier ou Construction
- Syndiqué: Oui
- Salaire: Modéré (7-10$/h en moyen)
- Avancement limitée: Faible mobilité professionnelle

Trajectoire Type 2 : Professionnel des Services

- Sector: Services, Administration
- Syndiqué: Habituellement Non
- Salaire: Variable (8-15$/h)
- Avancement: Accès potentiel au management

Trajectoire Type 3 : Cadre Éduqué

- Occupation: Manager, positions direction
- Éducation: Élevée (13+ années)
- Salaire: Élevé (15-25$/h)
- Secteur: Privé, services

0.6.3 Disparités Observées

Inégalités de Genre

- Représentation féminine faible dans la management (observé dans ACM)
- Distribution similaire en postes ouvriers
- Possible impact sur l'écart des salaires moyens

Variations Régionales

- Concentration sectorielle : Construction concentrée dans le Sud
- Accès différencié aux emplois selon région
- Implications pour les politiques régionales

Disparité Salariale Résiduelle

Même avec éducation et expérience contrôlées, variation importante des salaires suggère l'existence de facteurs additionnels (compétences spécifiques, performance, négociation, discrimination).

0.6.4 Validation des Hypothèses Économiques

Hypothèse 1 : Capital Humain

Confirmée : L'éducation et l'expérience sont significativement corrélées avec le salaire, confirmant la théorie du capital humain (Becker, 1964).

Évidence : Corrélations wage-education (0.451) et wage-experience (0.383).

Hypothèse 2 : Segmentation du Marché du Travail

Confirmée : L'existence de segments professionnels distincts avec caractéristiques propres (ACM).

Évidence : Quatre segments clairs avec mobilité limitée entre eux.

Hypothèse 3 : Inégalités Structurelles

Partiellement confirmée : Présence de disparités possiblement structurelles (genre, région).

Limites : Données transversales ne permettent pas de conclusion définitive sur causalité.

0.7 Conclusions

0.7.1 Résultats Clés

1. **Réduction dimensionnelle réussie** : 86% de variance capturée par 2 axes en ACP
2. **Facteurs salariaux identifiés** : Expérience > Éducation > Autres facteurs quantitatifs
3. **Segmentations naturelles** : Quatre groupes professionnels distincts
4. **Associations fortes** : Occupation-Secteur-Union très liées
5. **Disparités confirmées** : Genre et région montrent des patterns différencié

0.7.2 Qualité de l'Analyse

Points Forts

- Base de données de qualité (complète, 533 observations)
- Combinaison complémentaire ACP + ACM
- Visualisations claires et informatives
- Interprétation cohérente avec théories économiques

Limitations

- Données transversales (snapshot unique dans le temps)
- Causalité présumée, non démontrée
- Variables contextuelles manquantes (performance, compétences spécifiques)
- Contexte géographique particulier (résultats peuvent être spécifiques à une région/pays)

0.7.3 Implications Pratiques

Pour la Politique Éducative

L'éducation est un déterminant significatif du salaire. Les investissements en formation devraient être prioritaires, particulièrement pour accélérer la mobilité professionnelle.

Pour la Gestion des Ressources Humaines

L'expérience est hautement valorisée. Les entreprises devraient :

- Développer des programmes de formation continue
- Créer des parcours de carrière clairs
- Valoriser et reconnaître l'ancienneté

Pour les Politiques d'Égalité

Les disparités de genre et region identifiées suggèrent le besoin de :

- Politiques d'égalité des chances en accès management
- Développement économique régional balancé
- Monitoring des inégalités salariales

0.7.4 Recommandations pour Recherches Futures

1. **Études longitudinales** : Suivre les trajectoires individuelles dans le temps
2. **Data complémentaires** : Ajouter variables de performance, compétences spécifiques
3. **Modèles causaux** : Utiliser économétrie pour isoler effets causaux
4. **Analyse intersectionnelle** : Étudier intersections genre-région-occupation
5. **Comparaisons** : Analyser plusieurs régions/pays pour validité externe

0.7.5 Conclusion Finale

Cette analyse multivariée complète a démontré l'efficacité des méthodes ACP et ACM pour l'exploration et l'interprétation de données réelles. Les résultats fournissent une compréhension nuancée des déterminants de salaire et de la structure du marché du travail.

Les patterns identifiés - facteurs économiques classiques (éducation, expérience) combinés avec patterns socio-professionnels spécifiques (segmentation occupationnelle, disparités de genre) - reflètent la complexité du marché du travail réel.

Le projet a mis en lumière l'importance de combiner analyses quantitatives et qualitatives pour une compréhension holistique des phénomènes socio-économiques.

Références Bibliographiques

1. Becker, G. S. (1964). *Human Capital: A Theoretical and Empirical Analysis*. National Bureau of Economic Research.

2. Benzécri, J. P. (1992). *Analyse des données: Leçons sur l'analyse factorielle et la reconnaissance des formes*. Dunod.

3. Everitt, B. S., & Hothorn, T. (2011). *An Introduction to Applied Multivariate Analysis with R*. Springer. ISBN: 978-1-4419-9649-7.

4. Greenacre, M. J. (2007). *Correspondence Analysis in Practice* (2nd ed.). Chapman and Hall/CRC.

5. Hair, J. F., Black, W. C., Babin, B. J., & Anderson, R. E. (2019). *Multivariate Data Analysis* (8th ed.). Cengage Learning.

6. Hotelling, H. (1933). Analysis of a complex of statistical variables into principal components. *Journal of Educational Psychology*, 24(6), 417-441.

7. Husson, F., Lê, S., & Pagès, J. (2017). *Exploratory Multivariate Analysis by Example Using R*. CRC Press (2nd ed.).

8. Lebart, L., Piron, M., & Stehlé, B. (2000). *Traitement des données statistiques: Méthodes et programmes*. Dunod.

9. Tenenhaus, M., & Young, F. W. (1985). An analysis and synthesis of multiple correspondence analysis. *Psychometrika*, 50(1), 91–119.